## ۲.۱ نمایش کامپیوتری اعداد، با دقت متناهی

قبل از پیاده سازی عددی یک الگوریتم برای تحلیل یک مدل نیاز است دانشی پایه ای از چگونگی ذخیره سازی و نمایش اعداد و انجام محاسبات در ماشین داشته باشیم. در زندگی روزمره از اعداد در مبنای ۱۰ استفاده میکنیم اما کامپیوترها معمولاً بر مبنای دو استوار بوده و از حساب دودویی استفاده میکنند.

اعداد حقیقی را میتوان در مبنای عدد صحیحی همچون  $2 \geq \beta$  به صورت یک رشته ی نامتناهی مانند

$$x = (-1)^{\sigma} (b_n b_{n-1} \cdots b_0 . b_{-1} b_{-2} \cdots)_{\beta}$$
 (Y.1)

نمایش داد جایی که  $\sigma \in \{0,1\}$  اعدادی صحیح در بازه ی  $[0,\beta-1]$  بوده و  $b_n,b_{n-1},\cdots$  علامت عدد را مشخص می کند. عدد حقیقی متناظر برابر است با

$$x = (-1)^{\sigma} \sum_{i=-\infty}^{n} b_i \beta^i = (-1)^{\sigma} (b_n \beta^n + b_{n-1} \beta^{n-1} + \dots + b_0 + b_{-1} \beta^{-1} + b_{-2} \beta^{-2} + \dots).$$

وقتی یک عدد حقیقی به صورت (۲.۱) بیان شود، محل قرار گرفتن ممیز بسیار مهم است. دو قالب معروف برای اعداد عبارتند از قالب ممیز ثابت و قالب ممیز شناور. به طور ساده و غیرقیق، در قالب ممیز ثابت تعداد محلهایی از حافظه که بعد از علامت ممیز برای ذخیره ی اعداد، اختصاص می یابد ثابت است اما در قالب ممیز شناور با وجود اینکه تعداد محلهایی از حافظه که به کل عدد اختصاص می یابد ثابت است اما محل علامت ممیز انعطاف پذیر بوده و اعداد با تعداد ارقام متفاوت در قسمت بعد از ممیز قابل ذخیرهسازی هستند. بعنوان مثال فرض کنید یک قالب ممیز ثابت دهدهی

بتواند دو رقم اعشاری را ذخیره کند. پس در این قالب چنانچه کاربر هر یک از اعداد

12345.67

67123.45

1.23

و شبیه آن را وارد کند، امکان ذخیره و نمایش آنها بدون خطا وجود داشته اما عددی مانند 1.234 نمی تواند بدون خطا ذخیره شود. در مقابل فرض کنید در یک قالب ممیزشناور دهدهی، هفت رقم برای ذخیره ی تمام ارقام عدد اختصاص یافته باشد. در چنین قالبی چنانچه کاربر هر یک از اعداد

1.234567

123456.7

0.00001234567

123456700000

را وارد کند، امکان ذخیره و نمایش آنها بدون خطا ذخیره وجود دارد. جزییات بیشتر را بعدا خواهیم دید، در اینجا فقط به ذکر این نکته بسنده میکنیم که در قالب ممیز شناور، محل قرار گرفتن ممیز می می تواند با استفاده از تغییر قسمت توانِ عدد، شناور باشد. از یک زیست شناس که با میکروسکوپ کار میکند تا اختر شناسی که فواصل اجرام در کهکشانهای دوردست برایش مهم است با محاسبات علمی در گیر هستند. به همین دلیل مهم است که از قالبی در نمایش اعداد استفاده شود که بتواند اعداد با اندازههای از بسیار کوچک تا بسیار بزرگ را ذخیره کند. در نتیجه استفاده ی عملی از قالب ممیز ثابت که توان پایینی برای ذخیره ی اعداد با اندازههای متفاوت دارد بسیار محدودتر است.

یک عدد حقیقی در قالب ممیز شناور به صورت

$$x = (-1)^{\sigma} \ m \times \beta^e$$

نمایش داده می شود جایی که  $(-1)^{\sigma}$  علامت عدد است، m را **مانتیس** و e را **توان** عدد x می نامند. در این قالب ممیز شناور، می توان در صورت لزوم با تغییری مناسب در توان عدد، مانتیس را به صورت

$$m=(b_0.b_1b_2\cdots)_{\beta}$$

نوشت و همین نکته مزیت بزرگی برای نوشتن اعداد در قالب ممیز شناور در قیاس با نمایش (۲.۱) به وجود می آورد. به بیان صریح تر، وقتی عدد را به صورت ممیز شناور می نویسیم، سیستم داخلی ماشین از شرِّ تعقیبِ محل قرارگرفتن ممیز راحت می شود چرا که در این قالب، ممیز همیشه بعد از اولین رقم مانتیس قرار می گیرد. پس برای جمع بندی بحث تاکنون، مجموعه ی اعداد حقیقی در مبنای  $\beta$  را می توان در قالب ممیز شناور به صورت

$$F_{\beta} = \{ (-1)^{\sigma} \ m \times \beta^{e} \mid m = (b_{0}.b_{1}b_{2}\cdots)_{\beta} \}$$

نشان داد جایی که  $\beta$  عدد صحیحی بزرگتر یا مساوی دو،  $1-\beta \leq b_i \leq 0$  برای هر i، و i میتواند هر عدد صحیحی باشد. توجه کنید که نمایش اعداد با این شرایط یکتا نیست. مثلا عدد دهدهی i 123.4 میتواند با هر یک از نمایشهای

$$(1.234)_{10} \times 10^2 = (0.1234)_{10} \times 10^3 = (0.01234)_{10} \times 10^4$$

در این قالب ذخیره شود  $^{V}$  چرا که هر سه عدد با  $^{V}$  شرایط مجموعه ی  $^{V}$  را داشته و در نتیجه عضو این مجموعه هستند. برای منحصربفرد شدن نمایش اعداد، اِعمال شرط دیگری نیز  $^{V}$  است و آن این که رقم پیشروی  $^{V}$  ناصفر باشد. اعداد ممیز شناوری که در این شرط صدق میکنند را **نرمال** مینامند. نمایش عدد  $^{V}$  اعداد ممیز شناور نرمال دهدهی به صورت یکتای  $^{V}$  (1.234) در دستگاه اعداد ممیز شناور نرمال دهدهی به صورت یکتای  $^{V}$  که حافظه میباشد. مجموعه اعداد حقیقی  $^{V}$  یک مجموعه ی نامتناهی ناشماراست در حالی که حافظه محدود یک کامپیوتر تنها میتواند مقداری متناهی از اطلاعات را ذخیره کند. پس در عمل کامپیوترها تنها خواهند توانست زیرمجموعه ای متناهی از اعضای  $^{V}$  را ذخیره کرده و به صورت دقیق نمایش دهند. بعنوان گام بعدی برای نمایش اعداد در ماشین، مجموعه ی

$$F_{\beta,p} = \{ x \in F_\beta \mid m = (b_0.b_1b_2 \cdots b_{p-1})_\beta \}$$

دو نمایش  $^{\text{V}}$ دو نمایش  $^{\text{V}}$  دو نمایش  $^{$ 

را درنظر می گیریم که در آن p، دقت در ستگاه ممیز شناور نامیده می شود. این مجموعه هرچند شمارا اما همچنان نامتناهی است چرا که هیچ کرانی روی قسمت توان اعداد عضو آن اِعمال نشده است. مجموعه ای که اعضای آن با طبیعت ِ محدود حافظه ی ماشین سازگار باشند را می توان با مشخص کردن کرانهای پایین و بالا برای توان اعداد عضو  $F_{\beta,p}$  ساخت: بدین منظور فرض کنید L کران پایین و کران بالای مجاز برای توان باشد. در این صورت مجموعه ی ممیز شناور قابل نمایش به صورت دقیق در ماشین را می توان به صورت زیر تعریف کرد:

$$F_{\beta,p}^{L,U} = \{ x \in F_{\beta,p} \mid L \le e \le U \}.$$

با توجه به تعاریف بالا واضح است که داریم:

$$F_{\beta,p}^{L,U} \subset F_{\beta,p} \subset F_{\beta}$$

یعنی از مجموعه ی ناشمارای نامتناهی  $\mathbb R$  از اعداد حقیقی در ریاضیات چند مرحله عقبنشینی کرده ایم تا به مجموعه ی شمارای متناهی  $F_{\beta,p}^{L,U}$  که مجموعه ی اعداد ماشین نامیده می شود برسیم.

هثال ۲. اعداد نامنفی نرمال موجود در دستگاه  $F_{2,3}^{-1,2}$  را (به صورت اعدادی در مبنای ۱۰) مشخص کنید.

چون p=3 و p=3 و p=3 و جون چون چون جون p=3 و p=3 و p=3 و خون بیت برای ذخیره مانتیس اعداد داریم: p=3 و p=3 و خون بدنبال اعداد نرمال هستیم پس p=3 ، یعنی بیت p=3 فقط میتواند مقدار یک را اختیار کند. برای سادگی، توانها را در مبنای ۱۰ نشان می دهیم. به ازای p=3 اعداد زیر را در این دستگاه داریم:

$$(1.00)_2 \times 2^{-1} = (1 \times 2^0 + 0 \times 2^{-1} + 0 \times 2^{-2}) \times 2^{-1} = 1 \times \frac{1}{2} = 0.5,$$

$$(1.01)_2 \times 2^{-1} = (1 \times 2^0 + 0 \times 2^{-1} + 1 \times 2^{-2}) \times 2^{-1} = \frac{5}{8} = 0.625,$$

$$(1.10)_2 \times 2^{-1} = (1 \times 2^0 + 1 \times 2^{-1} + 0 \times 2^{-2}) \times 2^{-1} = \frac{6}{8} = 0.75,$$

$$(1.11)_2 \times 2^{-1} = (1 \times 2^0 + 1 \times 2^{-1} + 1 \times 2^{-2}) \times 2^{-1} = \frac{7}{8} = 0.875.$$

precision<sup>A</sup>

به ازای e=0، اعداد زیر را داریم:

$$(1.00)_2 \times 2^0 = (1 \times 2^0 + 0 \times 2^{-1} + 0 \times 2^{-2}) = \frac{8}{8} = 1,$$

$$(1.01)_2 \times 2^0 = (1 \times 2^0 + 0 \times 2^{-1} + 1 \times 2^{-2}) = \frac{10}{8} = 1.25,$$

$$(1.10)_2 \times 2^0 = (1 \times 2^0 + 1 \times 2^{-1} + 0 \times 2^{-2}) = \frac{12}{8} = 1.5,$$

$$(1.11)_2 \times 2^0 = (1 \times 2^0 + 1 \times 2^{-1} + 1 \times 2^{-2}) = \frac{14}{8} = 1.75.$$

به طرز مشابه برای e = +1 داریم:

$$(1.00)_2 \times 2^1 = 2,$$
  
 $(1.01)_2 \times 2^1 = \frac{20}{8} = 2.5,$   
 $(1.10)_2 \times 2^1 = \frac{24}{8} = 3,$   
 $(1.11)_2 \times 2^1 = \frac{28}{8} = 3.5.$ 

و نهایتا به ازای e = U = +2 اعداد زیر را داریم:

$$(1.00)_2 \times 2^2 = \frac{32}{8} = 4,$$
  

$$(1.01)_2 \times 2^2 = \frac{40}{8} = 5,$$
  

$$(1.10)_2 \times 2^2 = \frac{48}{8} = 6,$$
  

$$(1.11)_2 \times 2^2 = \frac{56}{8} = 7.$$

بنابراین اعداد نامنفی موجود در مجموعهی  $F_{23}^{-1,2}$  عبارتند از:

 $\{0.5, 0.625, 0.75, 0.875, 1, 1.25, 1.5, 1.75, 2, 2.5, 3, 3.5, 4, 5, 6, 7\}.$ 

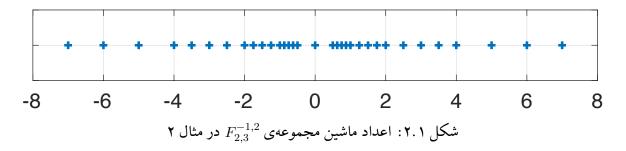
همانگونه که میبینیم کوچکترین عدد نرمال مثبت در مجموعه ی $F_{2,3}^{-1,2}$  برابر است با

$$N_{\text{min}} = (1.00)_2 \times 2^{-1} = 0.5$$

و بزرگترین عدد برابر است با

$$N_{\text{max}} = (1.11)_2 \times 2^2 = 7.$$

تعداد کل اعداد (منفی و مثبت) عضو مجموعهی شمارای  $F_{2,3}^{-1,2}$  برابر است با ۳۲. این اعداد به انضمام صفر در شکل ۲.۱ نمایش داده شدهاند.



نکتهی ۱. در مثال بالا فاصله ی بین اعداد متوالی متناظر با توان e=-1 برابر است با فاصله ی بین اعداد متوالی متناظر با توان e=0 برابر است با و e=0 برابر است با و e=0 به طور کلی هرچند فاصله ی بین اعداد ممیزشناور عضو دستگاه یکنواخت نیست اما برای هر توان و فیکس، فاصله ی بین اعداد متعلق به e=0 به e=0 برابر است با و e=0 برابر است با و فیکس، فاصله ی بین اعداد متعلق به e=0 به برابر است با و برابر است و برابر است با و برابر

نکتهی ۲. برای هر دو توان دلخواه m و n که در آن  $L \leq m, n \leq U$ ، تعداد اعضای (کاردینالیتی) هر دو مجموعهی  $F_{\beta,p}^{L,U} \cap [\beta^n, \beta^{n+1}]$  و  $F_{\beta,p}^{L,U} \cap [\beta^m, \beta^{m+1}]$  یکسان است.

 $x \in F_{\beta,p}^{L,U}$  نکتهی ۳. مجموعه ی اعداد ممیزشناور عضو  $x \in F_{\beta,p}^{L,U}$  نسبت به صفر متقارن است یعنی اگر  $-x \in F_{\beta,p}^{L,U}$  آنگاه  $-x \in F_{\beta,p}^{L,U}$ 

قمرین ۱. تعداد کل اعداد نرمال موجود در دستگاه ممیز شناور  $F_{eta,p}^{L,U}$  را بدست آورید.

دیدیم که هر عدد دودویی (eta=2) ممیزشناور نرمال موجود در دستگاهی با دقت p را میتوان به صورت

$$x = \pm (1.b_1b_2 \cdots b_{p-2}b_{p-1})_2 \times 2^e$$

ور حالت خاصی که U باشد هرچند کران بالای بازه یعنی  $g^{U+1}$  عضو دستگاه E=U نیست اما باز هم ورح در حالت خاصی که E=U بنیست اما بازه یعنی و بین اعداد متعلق به E=U بیکسان است چراکه نکته و بین اعداد متعلق به  $E_{\beta,p}^{L,U}\cap [\beta^U,\beta^{U+1}]$  یکسان است چراکه بین اعداد متعلق به E=U بین برقرار است. با استدلالی مشابه نکته و E=U برای حالت خاص E=U بین برقرار است.

نشان داد. واضح است که  $2^0 \times 2^0 \times 1 = (1.00 \cdots 00)_2 \times 2^0$  برابر است با

$$(1.00 \cdots 01)_2 \times 2^0 = 1 \times 2^0 + 0 \times 2^{-1} + \cdots + 0 \times 2^{-(p-2)} + 1 \times 2^{-(p-1)} = 1 + 2^{-(p-1)}$$
.

فاصله ی بین عدد یک و کوچکترین عدد بزرگتر از یک نقش بسیار مهمی در تحلیل خطای گردکردن در آنالیز عددی بازی میکند. این عدد را که اپسیلون ماشین ۱۰ نامیده می شود (در مبنای دو) برابر است با:

$$\varepsilon_M = 2^{-(p-1)}.$$

$$(1.00 \cdots 01)_{\beta} \times \beta^{e} = (1 + 0 + \cdots 0 + 1 \times \beta^{-(p-1)}) \times \beta^{e} = \tilde{x} + \beta^{-(p-1)} \times \beta^{e}$$

پس داریم:

$$ulp(x) = \beta^{e-p+1} = \varepsilon_M \beta^e.$$

دقت کنید که اگر x>0 باشد، آنگاه ulp(x) برابر است با فاصلهی بین x و عدد ممیز شناور بلافاصله بزرگتر از آن و اگر x>0 باشد، آنگاه ulp(x) برابر است با فاصلهی بین x و عدد ممیز شناور

machine epsilon'

unit in the last place

این فاصله در واقع برای تمام اعداد متعلق به فاصلهی بستهی  $[\beta^e,\beta^{e+1}]$  یکسان است مگر در حالت خاصی که e=U=2 یکسان است مگر در حالت خاصی دو e=U=1 که در این صورت، عدد نظیر عضو دستگاه نیست (در مثال قبل، به ازای e=U=1 عدد 8 حاصل می شد که اصلا عضو دستگاه نبود). برای جلوگیری از ایجاد مشکل در این حالت خاص است که بحث را در مورد  $F_{\beta,p}^{L,U}\cap[\beta^e,\beta^{e+1}]$ .

بلافاصله کوچکتر از x. بعلاوه میتوان دید که  $\varepsilon_M=ulp(1)$ . بار دیگر نکته ی ۱ را به یاد آورید. e=2 فواصلی که در آنجا ذکر شد همان ulp(x) بودند. بعنوان نمونه دیدیم که x=5 متناظر با توان و به همین خاطر داریم:

$$ulp(5) = 2^{2-3+1} = 2^0 = 1.$$

به طرز مشابه داریم:

$$ulp(1.75) = 2^{0-3+1} = 2^{-2} = 0.25,$$

که فاصلهی x=1.75 با کوچکترین عدد بزرگتر از آن است.